

UNIVERSIDAD DISTRITAL FRANCISCO JOSÉ
DE CALDAS

FACULTAD DE INGENIERÍA

INGENIERÍA DE SISTEMAS

Adaptación de modelos probabilísticos,
usando cópulas y grafos para la predicción
de brotes de dengue en zonas tropicales
de Colombia a partir del estudio
*Mechanistic modeling of social
conditions in disease-prediction
simulations via copulas and probabilistic
graphical models: HIV case study*

Asignatura: Probabilidad y Estadística

Docente: Alberto Acosta López

Grupo: 020-84

Estudiante: Alejandro Sánchez Escobar – 20222020252

Mayo de 2026

Bogotá D.C.

Índice

1. Introducción	2
2. Justificación	2
3. Tema de estudio	2
4. Pregunta de investigación	3
5. Objetivos	3
5.1. Objetivo general	3
5.2. Objetivos específicos	3
6. Paper base seleccionado	4
7. Marco teórico	4
8. Metodología	4
8.1. Fase 1. Revisión bibliográfica y definición del espacio probabilístico	5
8.2. Fase 2. Modelado de dependencias marginales y conjuntas	5
8.3. Fase 3. Estructura gráfica probabilística	5
8.4. Fase 4. Modelo de conteo y predicción	6
8.5. Fase 5. Estimación de parámetros	6
8.6. Fase 6. Validación	6
9. Resultados esperados	7
10. Discusión	8
11. Aplicación en Colombia	9
12. Conclusiones	9

1. Introducción

La probabilidad y la estadística permiten modelar fenómenos inciertos y apoyar decisiones en contextos reales. En esta propuesta se toma como base el artículo de Khosheghbal, Haas y Gopalappa, desarrollado en la University of Massachusetts Amherst y apoyado por instituciones como el CDC y la NSF, el cual emplea cópulas y modelos gráficos probabilísticos para simular condiciones sociales y su relación con la predicción de VIH [0].

La idea central de este trabajo es trasladar esa metodología a una problemática colombiana: la predicción de brotes de dengue en zonas tropicales. El dengue sigue siendo un evento relevante para la salud pública en Colombia y requiere herramientas cuantitativas que integren factores sociales, ambientales y epidemiológicos. La literatura reciente muestra además que los enfoques probabilísticos, los modelos gráficos y los modelos de cópulas continúan siendo muy activos en 2024, 2025 y 2026 en salud y predicción epidemiológica [0, 0, 0, 0, 0, 0, 0].

2. Justificación

Se elige este paper porque cumple con los requisitos de ser reciente, internacional, en inglés y con fuerte contenido estadístico. Además, usa herramientas como cópulas y grafos probabilísticos, directamente relacionadas con la asignatura. Su estructura metodológica puede adaptarse a Colombia para modelar el dengue, una enfermedad cuya dinámica depende de múltiples variables dependientes entre sí.

También es pertinente porque la investigación reciente en 2024–2026 sigue mostrando que los modelos probabilísticos y de grafos son útiles cuando se necesita explicabilidad, transporte entre escenarios y análisis multivariable en salud [0, 0, 0, 0, 0]. Ese marco es coherente con una propuesta de ingeniería de sistemas aplicada a salud pública.

3. Tema de estudio

El tema propuesto es la adaptación de un modelo probabilístico basado en cópulas y modelos gráficos para predecir brotes de dengue en Colombia, incorporando variables como temperatura, precipitación, densidad poblacional, acceso a agua y condiciones sociales.

4. Pregunta de investigación

¿Cómo puede adaptarse un modelo probabilístico basado en cópulas y modelos gráficos, originalmente aplicado a VIH en Estados Unidos, para predecir brotes de dengue en zonas tropicales de Colombia e identificar variables sociales y ambientales que influyen en el riesgo?

5. Objetivos

5.1. Objetivo general

Diseñar una propuesta de adaptación de un modelo probabilístico basado en cópulas y grafos para la predicción de brotes de dengue en Colombia.

5.2. Objetivos específicos

1. Analizar la estructura conceptual y estadística del paper base.
2. Identificar variables sociales, epidemiológicas y ambientales para el contexto colombiano.
3. Proponer una arquitectura de modelado probabilístico para dengue.
4. Relacionar el modelo con los contenidos de Probabilidad y Estadística.
5. Justificar la utilidad de la propuesta para optimizar recursos médicos y políticas de salud pública.

6. Paper base seleccionado

Cuadro 1: Ficha técnica del artículo base

Título	Mechanistic modeling of social conditions in disease-prediction simulations via copulas and probabilistic graphical models: HIV case study
Autores	Amir Khosheghbal, Peter J. Haas y Chaitra Gopalappa
Revista	<i>Health Care Management Science</i>
Año	2025
Institución principal	University of Massachusetts Amherst
Departamentos	Department of Mechanical and Industrial Engineering; Manning College of Information and Computer Sciences
Agencias asociadas	Centers for Disease Control and Prevention (CDC) y National Science Foundation (NSF)
DOI	10.1007/s10729-024-09694-3
Link del artículo	Springer
Registro académico	IDEAS/RePEc

7. Marco teórico

Las cópulas permiten combinar distribuciones marginales para construir una distribución conjunta $[0, 0, 0, 0, 0, 0]$. Los modelos gráficos probabilísticos representan dependencias condicionales entre variables $[0, 0, 0, 0]$. La construcción conjunta de ambas herramientas resulta útil para modelar fenómenos complejos como enfermedades infecciosas.

En problemas de salud, la literatura reciente muestra interés por modelos probabilísticos de predicción clínica, transporte de modelos entre sedes, y métodos semiparamétricos de riesgo que refuerzan la necesidad de explicabilidad y robustez $[0, 0]$. Esto justifica que el enfoque no sea solo predictivo, sino también interpretable.

8. Metodología

La metodología se desarrollará en cuatro fases y se apoyará en un modelo probabilístico multivariado. En términos matemáticos, la idea es representar la incidencia de dengue como una variable de respuesta Y_t y vincularla con un conjunto de covariables $X_t = (X_{1t}, X_{2t}, \dots, X_{pt})$, donde por ejemplo X_{1t} puede ser temperatura, X_{2t} precipitación, X_{3t} densidad poblacional y X_{4t} un índice social o de acceso a salud.

8.1. Fase 1. Revisión bibliográfica y definición del espacio probabilístico

Se partirá de un espacio de probabilidad $(\Omega, \mathcal{F}, \mathbb{P})$, donde Ω representa el conjunto de escenarios posibles de brote, $\mathcal{F}$ la colección de eventos y $\mathbb{P}$ la medida de probabilidad. Sobre ese espacio se definirán las variables aleatorias de interés. Esta etapa se apoya en el paper base y en estudios recientes de cópulas, grafos y predicción médica [0, 0, 0, 0, 0].

8.2. Fase 2. Modelado de dependencias marginales y conjuntas

Cada variable se modelará inicialmente con su distribución marginal:

$$F_Y(y) = \mathbb{P}(Y \leq y), \quad F_{X_i}(x_i) = \mathbb{P}(X_i \leq x_i), \quad i = 1, \dots, p.$$

Luego, las dependencias entre variables se integrarán mediante una cópula C_θ , de acuerdo con el teorema de Sklar:

$$F_{Y, X_1, \dots, X_p}(y, x_1, \dots, x_p) = C_\theta(F_Y(y), F_{X_1}(x_1), \dots, F_{X_p}(x_p)).$$

Si se trabaja con densidades, la función conjunta puede expresarse como:

$$f_{Y, X_1, \dots, X_p}(y, \mathbf{x}) = c_\theta(u_0, u_1, \dots, u_p) f_Y(y) \prod_{i=1}^p f_{X_i}(x_i),$$

donde $u_0 = F_Y(y)$ y $u_i = F_{X_i}(x_i)$. La selección de la familia de cópula se puede apoyar en el criterio de ajuste máximo de verosimilitud y en medidas de dependencia como Kendall o Spearman. Este paso está alineado con estudios recientes de cópula regresiva y selección de variables [0, 0, 0, 0, 0].

8.3. Fase 3. Estructura gráfica probabilística

La relación entre las variables se representará mediante un grafo dirigido acíclico o una red bayesiana. La factorización del modelo se plantea como:

$$\mathbb{P}(V_1, \dots, V_n) = \prod_{i=1}^n \mathbb{P}(V_i \mid \text{Pa}(V_i)),$$

donde $\text{Pa}(V_i)$ denota el conjunto de nodos padre de V_i . Esta formulación permitirá representar, por ejemplo, cómo la temperatura y la precipitación afectan la probabilidad

de brotes, y cómo esas condiciones se conectan con factores sociales y territoriales. La lógica está respaldada por literatura actual en grafos temporales, clasificación jerárquica y modelado gráfico mixto [0, 0, 0, 0, 0].

8.4. Fase 4. Modelo de conteo y predicción

Para la incidencia de dengue, una formulación razonable es un modelo de conteo. Si Y_t es el número de casos en el tiempo t , se puede asumir:

$$Y_t \sim \text{NegBin}(\mu_t, k),$$

con enlace logarítmico:

$$\log(\mu_t) = \beta_0 + \beta_1 T_t + \beta_2 R_t + \beta_3 H_t + \beta_4 D_t + \beta_5 S_t.$$

Aquí T_t representa temperatura, R_t precipitación, H_t humedad, D_t densidad poblacional y S_t una variable social compuesta. Este tipo de planteamiento es coherente con la literatura reciente de predicción de dengue con clima, variables ambientales y aprendizaje estadístico [mills2024climate, 0, 0, 0, 0, 0].

8.5. Fase 5. Estimación de parámetros

Los parámetros β y θ se estimarán por máxima verosimilitud, o en una versión extendida por inferencia bayesiana o EM cuando existan valores faltantes. La función objetivo general sería:

$$\hat{\Theta} = \arg \max_{\Theta} \sum_{t=1}^n \log f(y_t, \mathbf{x}_t \mid \Theta),$$

donde $\Theta = (\beta, \theta, k)$. La posibilidad de datos incompletos o mixtos justifica el uso de métodos robustos de ajuste [0, 0].

8.6. Fase 6. Validación

La predicción se validará con métricas como:

$$\text{MAE} = \frac{1}{n} \sum_{t=1}^n |y_t - \hat{y}_t|, \quad \text{RMSE} = \sqrt{\frac{1}{n} \sum_{t=1}^n (y_t - \hat{y}_t)^2},$$

$$\text{MAPE} = \frac{100}{n} \sum_{t=1}^n \left| \frac{y_t - \hat{y}_t}{y_t} \right|, \quad \Pr(Y_{t+h} > \tau \mid X_t).$$

Además, si el resultado se interpreta como clasificación de riesgo alto/bajo, se puede usar AUC, sensibilidad y especificidad. La validación cruzada por bloques temporales sería apropiada en escenarios epidemiológicos.

9. Resultados esperados

Se espera obtener una propuesta metodológica suficientemente clara para demostrar que el enfoque del paper base puede trasladarse al dengue en Colombia. Además, se busca producir un esquema formal que permita en una fase posterior construir un modelo de pronóstico operativo con datos reales.

En términos concretos, se esperan cuatro resultados. Primero, identificar qué variables sociales, territoriales y ambientales pesan más en la probabilidad de brote. Segundo, determinar si una cópula mejora la representación de dependencia entre variables frente a un enfoque independiente. Tercero, comparar el desempeño del modelo probabilístico con alternativas más simples. Cuarto, formular una ruta de implementación para apoyar decisiones de salud pública en zonas tropicales vulnerables.

La literatura reciente sugiere que los modelos de dengue con variables climáticas, de población y de contexto espacial sí pueden tener alto valor predictivo y operativo [mills2024climate, 0, 0, 0, 0, 0]. También se espera que la propuesta pueda explicar mejor la incertidumbre que un modelo puramente determinista.

Cuadro 2: Resumen de variables y salida esperada

Componente	Descripción	Papel en el modelo
Y_t	Casos de dengue en el tiempo t	Variable de respuesta
T_t	Temperatura promedio	Covariable climática
R_t	Precipitación	Covariable climática
H_t	Humedad	Covariable climática
D_t	Densidad poblacional	Covariable demográfica
S_t	Vulnerabilidad social compuesta	Covariable socio-económica
C_θ	Cópula seleccionada	Dependencia conjunta
μ_t	Media esperada	Pronóstico principal

10. Discusión

El paper de referencia fue construido para VIH en Estados Unidos, donde los determinantes sociales tienen una estructura distinta, pero el principio metodológico es el mismo: usar dependencia probabilística para no tratar las variables como independientes [0]. En Colombia, la adaptación debería reubicar el foco desde condiciones como aseguramiento, depresión o empleo hacia variables más sensibles al dengue: humedad, almacenamiento de agua, expansión urbana, movilidad local, densidad poblacional y acceso desigual a servicios de salud.

El valor del paper base no es únicamente su enfermedad objetivo, sino el modo en que integra variables heterogéneas en un sistema probabilístico explicable. Esa idea es muy útil para Colombia porque el dengue no se distribuye de manera uniforme: hay territorios con mayor exposición por clima tropical, mayor vulnerabilidad social y menor capacidad de respuesta institucional. La discusión sobre zonas tropicales, costeras y de transición urbano-rural debe enfatizar precisamente que el comportamiento de la enfermedad cambia por región, lo que hace imprescindible un modelo con dependencia espacial y temporal.

La evidencia reciente también muestra que el campo está avanzando en tres direcciones: pronóstico probabilístico, modelos gráficos interpretables y fusión de variables climáticas

con variables sociales [0, 0, 0, 0, 0]. En dengue, los estudios de 2024 y 2026 confirman que las variables ambientales, la predicción multi-horizonte y la transferencia del modelo a otros países de América Latina son viables [mills2024climate, 0, 0, 0, 0, 0].

Frente al contexto colombiano, el aporte esperado es doble. Por un lado, producir una lectura más fina del riesgo epidemiológico en municipios tropicales con alta vulnerabilidad. Por otro lado, generar una herramienta de decisión que ayude a priorizar control vectorial, campañas educativas, vigilancia y asignación de recursos médicos. Esa adaptación es especialmente útil en departamentos del Caribe, la Orinoquía y el Pacífico, donde la combinación de calor, lluvia, urbanización y desigualdad social favorece la transmisión.

11. Aplicación en Colombia

La aplicación esperada es la predicción de brotes, la optimización de recursos médicos y el apoyo a políticas de salud pública. En un país tropical, una propuesta probabilística como esta puede ayudar a anticipar territorios de alto riesgo y orientar intervenciones preventivas. También puede servir como base para una segunda fase donde se integren datos reales del INS, del clima y de la población para construir una versión operativa del modelo [mills2024climate, 0, 0, 0, 0].

12. Conclusiones

La propuesta es pertinente, actual y académicamente sólida. El artículo base ofrece una metodología avanzada y transferible, y su adaptación al dengue en Colombia es coherente con la realidad epidemiológica del país.

El aporte principal de esta propuesta es que no se limita a describir un problema, sino que formula un marco probabilístico formal para modelarlo. Al incorporar cópulas, grafos y un modelo de conteo, se obtiene una ruta teórica clara para pasar de la dependencia conceptual entre variables a un pronóstico cuantificable. Eso permite conectar directamente la materia con un caso real y útil.

Además, la revisión reciente muestra que la predicción de enfermedades, el modelado gráfico y las cópulas siguen siendo líneas activas en la literatura científica de 2024, 2025 y 2026 [mills2024climate, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0]. Por eso, el tema no solo es válido para el parcial, sino también fuerte como base para el paper final.

Referencias bibliográficas

- [0] Saeed Aldahmani, Othmane Kortbi y Mhamed Mesfioui. «Copula-Based Regression with Mixed Covariates». En: *Mathematics* 12.22 (2024), pág. 3525. DOI: 10.3390/math12223525. URL: <https://www.mdpi.com/2227-7390/12/22/3525> (visitado 07-05-2026).
- [0] Vizda Anam, Bruno V. Guerrero, Akhil Kumar Srivastav, Nico Stollenwerk y Máira Aguiar. «Within-host models unravelling the dynamics of dengue reinfections». En: *Infectious Disease Modelling* 9.2 (2024), págs. 458-473. DOI: 10.1016/j.idm.2024.02.004. URL: <https://pubmed.ncbi.nlm.nih.gov/38385021/> (visitado 07-05-2026).
- [0] Eduardo Correa Araujo, Luiz Max Carvalho, Fabiana Ganem, Luã Bida Vacaro, Leonardo S. Bastos, Laís Picinini Freitas et al. «Leveraging probabilistic forecasts for dengue preparedness and control: The 2024 Dengue Forecasting Sprint in Brazil». En: *Proceedings of the National Academy of Sciences of the United States of America* 123.7 (2026), e2508989123. DOI: 10.1073/pnas.2508989123. URL: <https://pubmed.ncbi.nlm.nih.gov/41678308/> (visitado 07-05-2026).
- [0] Moritz Berger, Nadja Klein, Michael Wagner y Matthias Schmid. «Modeling the ratio of correlated biomarkers using copula regression». En: *Statistical Modelling* 34.5 (2025). DOI: 10.1177/09622802241313293. URL: <https://journals.sagepub.com/doi/10.1177/09622802241313293> (visitado 07-05-2026).
- [0] Guillermo Briseño Sanchez, Nadja Klein, Hannah Klinkhammer y Andreas Mayr. «Boosting distributional copula regression for bivariate binary, discrete and mixed responses». En: *Statistical Modelling* 34.5 (2025). DOI: 10.1177/09622802241313294. URL: <https://journals.sagepub.com/doi/10.1177/09622802241313294> (visitado 07-05-2026).
- [0] Jiayuan Chen, Changchang Yin, Yuanlong Wang y Ping Zhang. «Predictive Modeling with Temporal Graphical Representation on Electronic Health Records». En: *Proceedings of the Thirty-Third International Joint Conference on Artificial Intelligence (IJCAI-24)*. 2024, págs. 5763-5771. DOI: 10.24963/ijcai.2024/637. URL: <https://www.ijcai.org/proceedings/2024/637> (visitado 07-05-2026).
- [0] Shengqiang Chi, Yuqing Wang, Ying Zhang, Weiwei Zhu y Jingsong Li. «Graph Neural Network Based Multi-Label Hierarchical Classification for Disease Predictions in General Practice». En: *MEDINFO 2023 – The Future Is Accessible*. 2024. DOI: 10.3233/SHTI231060. URL: <https://doi.org/10.3233/SHTI231060> (visitado 07-05-2026).

- [0] Rasika Dalpadado, Deepika Amarasinghe, Nayana Gunathilaka y Annista N. Wijayanayake. «Forecasting dengue incidence based on entomological indices, population density, and meteorological and environmental variables in the Gampaha District of Sri Lanka». En: *Heliyon* 10.11 (2024), e32326. DOI: 10.1016/j.heliyon.2024.e32326. URL: <https://pubmed.ncbi.nlm.nih.gov/38912438/> (visitado 07-05-2026).
- [0] Bowen Gu, Rishi J. Desai, Kueiyu Joshua Lin y Jie Yang. «Probabilistic medical predictions of large language models». En: *npj Digital Medicine* 7 (2024), pág. 367. DOI: 10.1038/s41746-024-01366-4. URL: <https://www.nature.com/articles/s41746-024-01366-4> (visitado 07-05-2026).
- [0] Jill Hasler, Yanyuan Ma, Yizheng Wei, Ravi Parikh y Jinbo Chen. «A semiparametric method for risk prediction using integrated electronic health record data». En: *The Annals of Applied Statistics* 18.4 (2024), págs. 3318-3337. DOI: 10.1214/24-AOAS1938. URL: <https://pubmed.ncbi.nlm.nih.gov/40134753/> (visitado 07-05-2026).
- [0] Amir Khosheghbal, Peter J. Haas y Chaitra Gopalappa. «Mechanistic modeling of social conditions in disease-prediction simulations via copulas and probabilistic graphical models: HIV case study». En: *Health Care Management Science* 28 (2025), págs. 28-49. DOI: 10.1007/s10729-024-09694-3. URL: <https://link.springer.com/article/10.1007/s10729-024-09694-3> (visitado 07-05-2026).
- [0] Yanke Li, Anke Scheel-Sailer, Robert Riener, Diego Paez-Granados et al. «Mixed-variable graphical modeling framework towards risk prediction of hospital-acquired pressure injury in spinal cord injury individuals». En: *Scientific Reports* 14 (2024), pág. 25067. DOI: 10.1038/s41598-024-75691-9. URL: <https://www.nature.com/articles/s41598-024-75691-9> (visitado 07-05-2026).
- [0] Eckhard Liebscher. «Fitting copulas in the case of missing data». En: *Statistical Papers* 65 (2024), págs. 3681-3711. DOI: 10.1007/s00362-024-01535-3. URL: <https://link.springer.com/article/10.1007/s00362-024-01535-3> (visitado 07-05-2026).
- [0] Bushra Mazhar, Nazish Mazhar Ali, Farkhanda Manzoor, Muhammad Kamran Khan, Muhammad Nasir y Muhammad Ramzan. «Development of data-driven machine learning models and their potential role in predicting dengue outbreak». En: *Journal of Vector Borne Diseases* 61.4 (2024), págs. 503-514. DOI: 10.4103/0972-9062.393976. URL: <https://pubmed.ncbi.nlm.nih.gov/38238798/> (visitado 07-05-2026).

- [0] Cathal Mills y Christl A. Donnelly. «Climate-based modelling and forecasting of dengue in three endemic departments of Peru». En: *PLOS Neglected Tropical Diseases* 18.12 (2024), e0012596. DOI: 10.1371/journal.pntd.0012596. URL: <https://pubmed.ncbi.nlm.nih.gov/39630856/> (visitado 07-05-2026).
- [0] Alessandro Sebastianelli, Dario Spiller, Raquel Carmo, James Wheeler, Artur Nowakowski, Ludmilla Viana Jacobson, Dohyung Kim, Hanoch Barlevi, Zoraya El Raiss Cordero, Felipe J. Colón-González, Rachel Lowe, Silvia Liberata Ullo et al. «A reproducible ensemble machine learning approach to forecast dengue outbreaks». En: *Scientific Reports* 14 (2024), pág. 3807. DOI: 10.1038/s41598-024-52796-9. URL: <https://www.nature.com/articles/s41598-024-52796-9> (visitado 07-05-2026).
- [0] Sidney T. da Silva, Enrique C. Gabrick, Paulo R. Protachevycz, Kelly C. Iarosz, Iberê L. Caldas et al. «When climate variables improve the dengue forecasting: a machine learning approach». En: *The European Physical Journal Special Topics* 234 (2024), págs. 555-569. DOI: 10.1140/epjs/s11734-024-01201-7. URL: <https://link.springer.com/article/10.1140/epjs/s11734-024-01201-7> (visitado 07-05-2026).
- [0] Annika Strömer, Nadja Klein, Christian Staerk, Florian Faschingbauer, Hannah Klinkhammer y Andreas Mayr. «Enhanced variable selection for boosting sparser and less complex models in distributional copula regression». En: *Statistics in Biosciences* 17 (2025), págs. 1-31. DOI: 10.1007/s12561-025-09491-8. URL: <https://link.springer.com/article/10.1007/s12561-025-09491-8> (visitado 07-05-2026).
- [0] Xuan Sun, Jianyuan Guo, Yong Qin, Xuanchuan Zheng, Shifeng Xiong, Jie He, Qi Sun y Limin Jia. «A spatiotemporal probabilistic graphical model based on adaptive expectation-maximization attention for individual trajectory reconstruction considering incomplete observations». En: *Entropy* 26.5 (2024), pág. 388. DOI: 10.3390/e26050388. URL: <https://www.mdpi.com/1099-4300/26/5/388> (visitado 07-05-2026).
- [0] Shuang Wang, Jin-Xing Liu, Feng Li, Juan Wang y Ying-Lian Gao. «M³HOGAT: A multi-view multi-modal multi-scale high-order graph attention network for microbe-disease association prediction». En: *IEEE Journal of Biomedical and Health Informatics* 28.10 (2024), págs. 6259-6267. DOI: 10.1109/JBHI.2024.3429128. URL: <https://doi.org/10.1109/JBHI.2024.3429128> (visitado 07-05-2026).